Selección de Modelos y Regularización

Big Data y Machine Learning para Economía Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

1. Previously...
2. Selección de Modelos
3. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Implementación

Agenda

1. Previously...
2. Selección de Modelos
3. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Implementación

El objetivo: $Y = m(W) + u$

- Para cualquier variable aleatoria Y y vector de covariables W, tenemos:

$$y = m(W) + u$$

- Bajo pérdida cuadrática, para cualquier función medible $m(W)$:

$$\mathbb{E}[Y \mid W] \;=\; \arg\min_{m} \; \mathbb{E}\left[(Y - m(W))^2\right]$$

- El problema práctico
  - La CEF es el objetivo, pero:
    1. No observamos W directamente — observamos X (aproximación ruidosa).
    2. Desconocemos la forma funcional de $m(W)$.
  - Todo lo que sigue es la respuesta a cómo lidiar con esto.

Restringiendo a la clase lineal: el BLP

- Supongamos que *conocemos* W. Buscamos el mejor predictor **lineal**:

$$\boldsymbol{\beta}^* = \arg\min_{\boldsymbol{\beta}} \ \mathbb{E}\left[(Y - W'\boldsymbol{\beta})^2\right]$$

- **Condición de primer orden** (diferenciando e igualando a cero):

$$\mathbb{E}\left[W(Y - W'\boldsymbol{\beta})\right] = 0 \quad \Longrightarrow \quad \boxed{\boldsymbol{\beta}^* = \left[\mathbb{E}(WW')\right]^{-1}\mathbb{E}(WY)}$$

- El **Best Linear Predictor** es $W'\boldsymbol{\beta}^*$.

- BLP $\neq$ CEF en general: $W'\boldsymbol{\beta}^* = \mathbb{E}[Y \mid W]$ *solo si* $\mathbb{E}[Y \mid W]$ es lineal en W

Restringiendo a la clase lineal: el BLP

La descomposición con el BLP

- Partiendo de $Y = m(W) + u$ (con $\mathbb{E}[u \mid W] = 0$):

$$Y = \underbrace{W'\boldsymbol{\beta}^*}_{\text{BLP}} + \underbrace{\left(\mathbb{E}[Y \mid W] - W'\boldsymbol{\beta}^*\right)}_{\eta\text{: error de no-linealidad}} + \underbrace{u}_{\text{irreducible}}$$

  - η no desaparece a menos que $m(W)$ sea exactamente lineal.
  - El BLP minimiza el MSE dentro de la clase lineal, *no* globalmente.

- Mapa de errores (hasta aquí)

$$\underbrace{\mathbb{E}[Y \mid W]}_{\text{CEF}} \xrightarrow{\text{linealizar}} \underbrace{W'\boldsymbol{\beta}^*}_{\text{BLP}} \quad \text{con error } \eta$$

Dos problemas, una estrategia

- En la práctica enfrentamos simultáneamente:
  1. No observamos W, solo X, subconjunto o versión ruidosa de W.
  2. $\mathbb{E}[Y \mid W]$ probablemente no es lineal en W.

- **Estrategia:** construir un **diccionario de predictores**

$$g(X) = \big(g_1(X), g_2(X), \ldots, g_p(X)\big)'$$

donde cada g_j es una transformación de X: polinomios, interacciones $X_i X_j$, etc.

  - La linealidad en $\boldsymbol{\beta}$ **no** es una restricción sobre la forma funcional es una restricción sobre cómo combinamos un diccionario que *nosotros elegimos*.
  - Con $g(X)$ suficientemente rico, podemos aproximar cualquier $\mathbb{E}[Y \mid W]$ suave.

Restringiendo a la clase lineal: el BLP

La descomposición completa de errores

- El BLP de Y sobre $g(X)$ es $g(X)'\boldsymbol{\beta}^*$ con $\boldsymbol{\beta}^* = [\mathbb{E}(g(X)g(X)')]^{-1}\mathbb{E}(g(X)Y)$.

$$Y = \underbrace{g(X)'\boldsymbol{\beta}^*}_{\text{BLP aprox.}} + \underbrace{\left(\mathbb{E}[Y \mid W] - g(X)'\boldsymbol{\beta}^*\right)}_{\eta\text{: error de especificación}} + \underbrace{u}_{\text{irreducible}}$$

- Mapa completo del problema (teórico)

$$\underbrace{\mathbb{E}[Y \mid W]}_{\text{CEF}} \xrightarrow{\text{linealizar}} \underbrace{W'\boldsymbol{\beta}^*}_{\text{BLP en } W} \xrightarrow{W \to g(X)} \underbrace{g(X)'\boldsymbol{\beta}^*}_{\text{BLP aprox.}} \xrightarrow{\text{estimar}} \underbrace{g(X)'\hat{\boldsymbol{\beta}}}_{\text{predictor}}$$

Error de predicción fuera de muestra

- ML nos interesa la predicción fuera de muestra
- Para un nuevo punto x_0, el error cuadrático esperado es:

$$\underbrace{\mathbb{E}\left[(Y_0 - g(x_0)'\hat{\boldsymbol{\beta}})^2\right]}_{\text{Error de Predicción Esperado}} = \underbrace{\sigma_u^2}_{\text{irreducible}} + \underbrace{\left(\mathbb{E}[Y_0 \mid W_0] - g(x_0)'\boldsymbol{\beta}^*\right)^2}_{\text{Sesgo}^2} + \underbrace{\mathbb{E}\left[(g(x_0)'\hat{\boldsymbol{\beta}} - g(x_0)'\boldsymbol{\beta}^*)^2\right]}_{\text{Varianza}} \tag{1}$$

Error de predicción fuera de muestra

- ML nos interesa la predicción fuera de muestra
- Para un nuevo punto x_0, el error cuadrático esperado es:

$$\underbrace{\mathbb{E}\left[(Y_0 - g(x_0)'\hat{\boldsymbol{\beta}})^2\right]}_{\text{Error de Predicción Esperado}} = \underbrace{\sigma_u^2}_{\text{irreducible}} + \underbrace{\left(\mathbb{E}[Y_0 \mid W_0] - g(x_0)'\boldsymbol{\beta}^*\right)^2}_{\text{Sesgo}^2} + \underbrace{\mathbb{E}\left[(g(x_0)'\hat{\boldsymbol{\beta}} - g(x_0)'\boldsymbol{\beta}^*)^2\right]}_{\text{Varianza}} \quad (1)$$

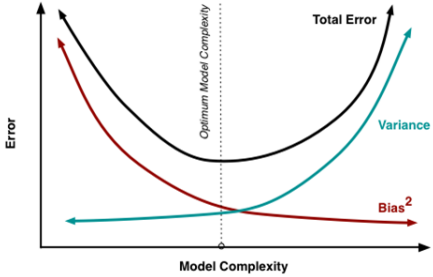

Error de predicción fuera de muestra

- ML nos interesa la predicción fuera de muestra, pero contamos con una muestra
- Overfit: modelos complejos predicen muy bien dentro de muestra, pero tienden a hacer un mal trabajo fuera de muestra

Error de predicción fuera de muestra

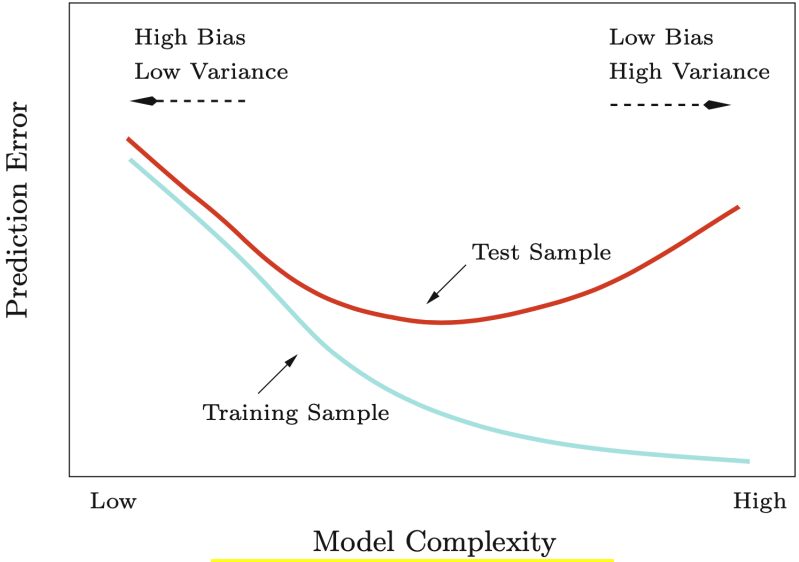

Error de predicción fuera de muestra

- En el modelo lineal, la diferencia entre los dos errores:

$$\text{MSE}_{\text{fuera}} = \text{MSE}_{\text{dentro}} + \underbrace{2 \cdot \frac{p}{N} \cdot \sigma_u^2}_{\text{"optimismo"}}$$

  - El "optimismo" crece linealmente en p/N.
  - Derivar este optimismo bajo ciertos supuestos es lo que hacen AIC, BIC, etc.
  - Los métodos de remuestreo estiman el optimismo directamente sin asumir nada, por eso es más general y es el estándar en ML. Cuando p/N **no** es pequeño, la aproximación del AIC, BIC, etc. se rompe y CV gana.

Agenda

1 Previously...

2 Selección de Modelos

3 Regularización
- Recap: OLS Mechanics
- Ridge
- Implementación

Model Subset Selection

- We have M_k models
- We want to find the model that best predicts out of sample
- We have a number of ways to go about it
  - Best Subset Selection
  - Stepwise Selection
    - Forward selection
    - Backward selection

Agenda

1 Previously...

2 Selección de Modelos

3 Regularización
- Recap: OLS Mechanics
- Ridge
- Implementación

Agenda

1. Previously...
2. Selección de Modelos
3. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Implementación

Regularización: Motivación

- OLS minimiza el error *"dentro de muestra"*, eligiendo β de forma tal que

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 \tag{2}$$

OLS 1 Dimension

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 \tag{3}$$

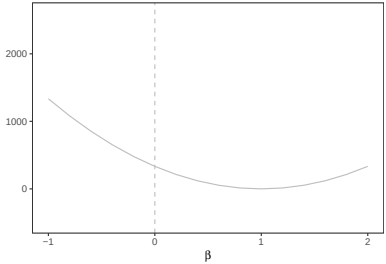

App

OLS 2 Dimensiones

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \tag{4}$$

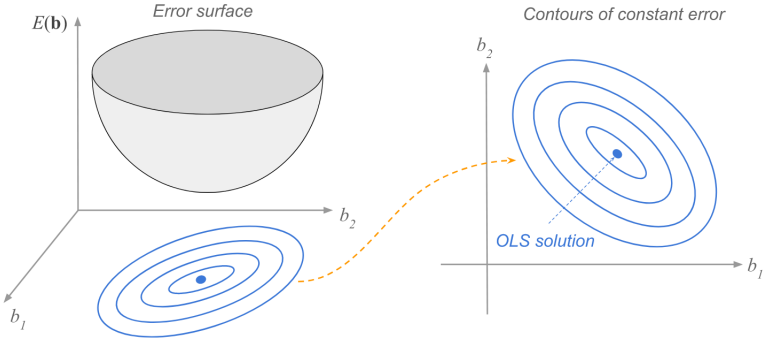

Fuente: https://allmodelsarewrong.github.io

App

Regularización: Motivación

- OLS minimiza el error *"dentro de muestra"*, eligiendo β de forma tal que

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 \tag{2}$$

- pero para predicción, no estamos interesados en hacer un buen trabajo dentro de muestra
- Queremos hacer un buen trabajo, **fuera de muestra**

Agenda

1. Previously...
2. Selección de Modelos
3. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Implementación

Regularización

- Asegurar cero sesgo dentro de muestra crea problemas fuera de muestra: trade-off Sesgo-Varianza
- Las técnicas de machine learning fueron desarrolladas para hacer este trade-off de forma empírica.
- Vamos a proponer modelos del estilo

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^{p} R(\beta_j) \tag{5}$$

- donde R es un regularizador que penaliza funciones que crean varianza

Ridge

- Para un $\lambda \geq 0$ dado, consideremos ahora el siguiente problema de optimización

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^{p} (\beta_j)^2 \tag{6}$$

Ridge: Intuición en 1 Dimension

- 1 predictor estandarizado
- El problema:

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta^2 \tag{7}$$

- La solución?

App

Ridge: Intuición en 1 Dimension

Problema como optimización restringida

- Existe un $c > 0$ tal que $\hat{\beta}(\lambda)$ es la solución a

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 \tag{8}$$

$$\text{sujeto a}$$

$$(\beta)^2 < c$$

Ridge: Intuición en 1 Dimension

Problema como optimización restringida

Ridge: Intuición en 2 Dimensiones

- Al problema en 2 dimensiones podemos escribirlo como

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i2}\beta_2 + \lambda \left(\beta_1^2 + \beta_2^2\right) \tag{9}$$

- podemos escribirlo como un problema de optimización restringido

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \tag{10}$$

sujeto a

$$\left((\beta_1)^2 + (\beta_2)^2\right) < c$$

Ridge: Intuición en 2 Dimensiones

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } \left((\beta_1)^2 + (\beta_2)^2\right) \leq c \tag{11}$$

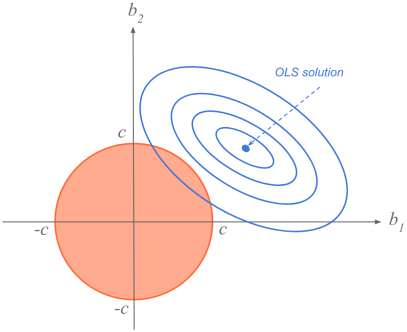

Fuente: `https://allmodelsarewrong.github.io`

Ridge: Intuición en 2 Dimensiones

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } \left((\beta_1)^2 + (\beta_2)^2\right) \leq c \tag{12}$$

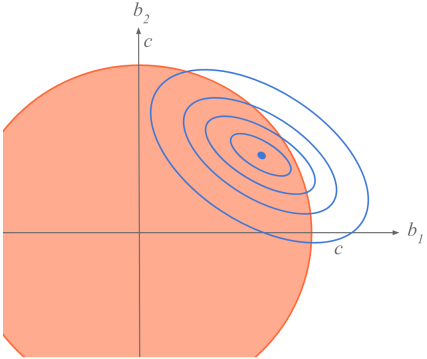

Fuente: https://allmodelsarewrong.github.io

Ridge: Intuición en 2 Dimensiones

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } \left((\beta_1)^2 + (\beta_2)^2\right) \leq c \tag{13}$$

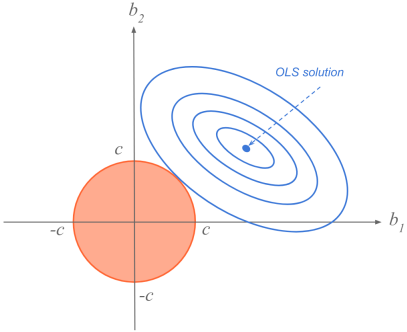

Fuente: https://allmodelsarewrong.github.io

Ridge: Intuición en 2 Dimensiones

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } \left((\beta_1)^2 + (\beta_2)^2\right) \leq c \tag{14}$$

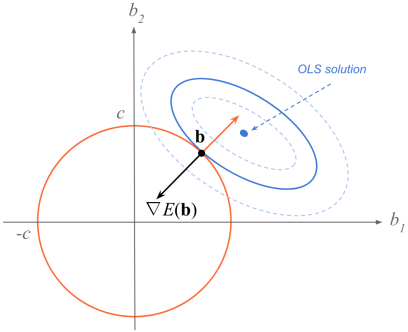

Fuente: https://allmodelsarewrong.github.io

Términos generales

- En regresión multiple (X es una matriz $n \times k$)
- Regresión: $y = X\beta + \varepsilon$
- OLS

$$\hat{\beta}_{ols} = (X'X)^{-1}X'y$$

- Ridge

$$\hat{\beta}_{ridge} = (X'X + \lambda I)^{-1}X'y$$

Ridge vs OLS

- Ridge es sesgado $E(\hat{\beta}_{ridge}) \neq \beta$

Ridge vs OLS

- Ridge es sesgado $E(\hat{\beta}_{ridge}) \neq \beta$
- Pero la varianza es menor que la de OLS

Ridge vs OLS

- Ridge es sesgado $E(\hat{\beta}_{ridge}) \neq \beta$
- Pero la varianza es menor que la de OLS
- Para ciertos valores del parámetro $\lambda \Rightarrow MSE_{OLS} > MSE_{ridge}$

Agenda

1. Previously...
2. Selección de Modelos
3. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Implementación

Escala de las variables

- La escala de las variables importa en Ridge, mientras que en OLS no.
- Es importante estandarizar las variables X:

$$X^{std} = \frac{X - \mu_X}{\sigma_X} \tag{15}$$

Selección de λ

- Asegurar cero sesgo dentro de muestra crea problemas fuera de muestra: trade-off Sesgo-Varianza
- Ridge hace este trade-off de forma empírica.

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^{p} R(\beta_j) \tag{16}$$

- λ es el precio al que hacemos este trade off
- Como elegimos λ?

Selección de λ (K-fold CV)

- λ es un hiperparámetro: lo elegimos por validación cruzada.
- Partimos el set de entrenamiento en K folds:

$$\mathcal{D} = \bigcup_{k=1}^{K} \mathcal{D}^{(k)}, \qquad \mathcal{D}^{(k)} \cap \mathcal{D}^{(\ell)} = \emptyset \; (k \neq \ell).$$

- En el fold k:

$$\text{entrenamos en } \mathcal{D}_{-k} \equiv \mathcal{D} \setminus \mathcal{D}^{(k)} \quad \text{y evaluamos en } \mathcal{D}^{(k)}.$$

Selección de λ (Algoritmo)

- Para cada $\lambda \in \{\lambda_1, \ldots, \lambda_L\}$:
  - Para $k = 1, \ldots, K$:
    - Ajustar $\widehat{f}_{\lambda,k}$ usando $\mathcal{D}_{-k}$
    - Calcular $MSE_{\lambda,k}$ en $\mathcal{D}^{(k)}$
  - Promediar:

$$CV(\lambda) = \frac{1}{K} \sum_{k=1}^{K} MSE_{\lambda,k}$$

- Elegir:

$$\lambda^* = \arg\min_{\lambda} CV(\lambda)$$

Review

$$\underbrace{\mathbb{E}[Y \mid W]}_{\text{CEF (objetivo)}} \xrightarrow{\text{linealizar}} \underbrace{W'\beta^*}_{\text{BLP}} \xrightarrow{W \to g(X)} \underbrace{g(X)'\beta^*}_{\text{BLP aprox.}} \xrightarrow{\text{estimar}} \underbrace{g(X)'\hat{\beta}}_{\text{predictor}}$$

- Error de Predicción Esperado (MSE)

$$\text{MSE} = \sigma_u^2 + \text{Sesgo}^2 + \text{Varianza}$$

  - **Sesgo**^{2}: propiedad del *modelo* $g(X)$. Baja al enriquecer $g(X)$. No depende de N.
  - **Varianza**: propiedad del *estimador*. Para OLS: $\sigma_u^2 \cdot p/N$. Sube con p.
- Dentro vs. fuera de muestra

$$\text{MSE}_{\text{fuera}} = \text{MSE}_{\text{dentro}} + \underbrace{2\,\frac{p}{N}\,\sigma_u^2}_{\text{"optimismo"}}$$

- Regularización: Ridge penaliza $\|\beta\|^2$ con parámetro λ:
  - Introduce sesgo deliberadamente.
  - Reduce varianza
  - λ se elige por validación cruzada.